FICHE D'ACTIVITÉ

CAS PRATIQUE

Fraude et segmentation

Activité 10

M1/ INFO IA DATA /Machine learning

Objectifs

- Analyser un dataset réel et déséquilibré pour produire un jeu de données propre et exploitable.
- Concevoir ≥3 features pertinentes et mesurer leur impact sur les performances.
- Comparer ≥2 modèles supervisés en gérant le déséquilibre et en justifiant les métriques en fraude.
- Appliquer clustering et détection d'anomalies, puis livrer un pipeline ML robuste et interprétable.

Instructions

Contexte : Une fintech souhaite développer un système intelligent capable :

1. De détecter automatiquement les transactions frauduleuses
2. De segmenter les comportements clients
3. D'identifier des transactions anormales

Le système devra être capable :

- De traiter des données réelles bruitées
- De gérer un fort déséquilibre de classes
- D'intégrer du feature engineering pertinent
- D'être implémenté via un pipeline robuste

Datasets

1. Dataset principal : Credit Card Fraud Detection

Contenu :

- 284 807 transactions
- 30 variables numériques (PCA déjà appliquée)
- Time
- Amount
- Class (0 = normal, 1 = fraude)
- Dataset extrêmement déséquilibré (~0.17% de fraudes)

Outils pédagogiques et moyens associés

Python : pandas, scikit-learn (+ imbalanced-learn pour SMOTE), matplotlib/seaborn.

Notebook propre, structuré et commenté ; graphiques lisibles ; interprétation métier obligatoire.

Ressources :

- Credit Card Fraud Detection (Kaggle) : https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud
- Bank Marketing Dataset (UCI) : https://archive.ics.uci.edu/static/public/222/bank+marketing.zip

Bonus : GridSearch, TPOT ou H2O AutoML.

Livrable(s)

- Notebook .ipynb exécutable, structuré et commenté.
- Justifier chaque choix technique en 2–3 lignes dans le notebook.
- Slides de soutenance (15 min max) : compréhension du problème, difficultés, choix techniques, comparaison des modèles, résultats finaux, recommandation business.

Points d'attention

Barème indicatif :

- Compréhension/EDA (2) : Analyse pertinente, déséquilibre identifié, graphiques cohérents, lecture critique ;
- Nettoyage (2) : Gestion des valeurs manquantes, justification des choix, cohérence ;
- Feature Engineering (3) : Création pertinente de features, justification, impact mesuré ;
- Modélisation supervisée (4) : Au moins 2 modèles, comparaison claire, gestion du déséquilibre ;
- Métriques/analyse critique (2) : Justification Precision vs Recall, matrice de confusion, … ;
- Non supervisé (3) : Clustering pertinent, silhouette, interprétation business ;
- Pipeline (2) : Pipeline propre, organisation claire ;
- Présentation (2,5) : Clarté, pédagogie, structure, défense orale ;
- Questions (1,5) : Capacité d'argumentation, esprit critique, justification.

Interprétation business attendue (clusters, anomalies, recommandations).

FICHE D'ACTIVITÉ

CAS PRATIQUE

Fraude et segmentation

Activité 10

ynov CAMPUS

Instructions

2. Dataset complémentaire

Bank Marketing Dataset

Objectif :

- Segmenter les clients
- Travailler sur variables catégorielles
- Appliquer encodage, normalisation

Travail demandé

Le projet est divisé en 5 parties :

PARTIE 1 - Exploration & Nettoyage

- Analyse exploratoire (EDA)
- Analyse du déséquilibre
- Gestion des valeurs manquantes (si présentes)
- Détection d'outliers
- Analyse des corrélations
- Distribution des variables
- Analyse du comportement de Amount et Time

Livrable attendu :

- Code commenté
- Graphiques pertinents
- Justification des choix de nettoyage

PARTIE 2 - Feature Engineering

Vous devez créer au minimum 3 nouvelles caractéristiques pertinentes

Exemples :

- Montant log-transformé
- Ratio transaction/moyenne client
- Indicateur temporel (jour/nuit)
- Normaliser ou standardiser les variables si nécessaire
- Justifier le choix d'encodage
- Comparer performance avec et sans feature engineering

Bonus :

- Sélection de variables
- PCA

PARTIE 3 - Modélisation Supervisée

Construire et comparer au moins 2 modèles différents :

Exemples :

- Régression Logistique
- Arbre de décision
- Random Forest
- SVM
- MLP

Contraintes :

- Split train/test propre
- Cross-validation
- Gestion du déséquilibre (SMOTE ou class_weight)
- Métriques :
- Precision
- Recall
- F1-score
- ROC-AUC
- Matrice de confusion

Important : Justifier quelle métrique est prioritaire dans un contexte de fraude.

FICHE D'ACTIVITÉ

CAS PRATIQUE

Fraude et segmentation

Activité 10

ynov CAMPUS

Correction

PARTIE 4 - Apprentissage Non Supervisé

Objectifs :

1. Clustering des transactions :
   - o K-means
   - o DBSCAN (fortement recommandé)
   - o Choix du nombre optimal de clusters
2. Détection d'anomalies :
   - o Isolation Forest
   - o Local Outlier Factor
   - o Comparaison avec la variable fraude réelle

Mesures :

- Silhouette score
- Interprétation business des clusters

PARTIE 5 — Pipeline & AutoML

Construire un pipeline complet incluant :

- Preprocessing
- Feature engineering
- Modèle
- Cross-validation

Bonus :

- GridSearch
- TPOT ou H2O AutoML

Objectif :

Montrer que vous maîtrisez la structuration propre d'un projet ML.

Contraintes techniques

- Python (pandas, Scikit-learn, seaborn, ...)
- Notebook propre et structuré
- Code commenté
- Graphiques lisibles
- Interprétation métier obligatoire

Livrables attendus

Chaque binôme devra rendre :

1. Notebook (.ipynb)
   - Exécutable
   - Structuré
   - Commenté
   - Chaque choix technique doit être justifié en 2-3 lignes dans le notebook
2. Slides (15 minutes max)

Contenu attendu :

1. Compréhension du problème
2. Difficultés rencontrées
3. Choix techniques
4. Comparaison des modèles
5. Résultats finaux
6. Recommandation business