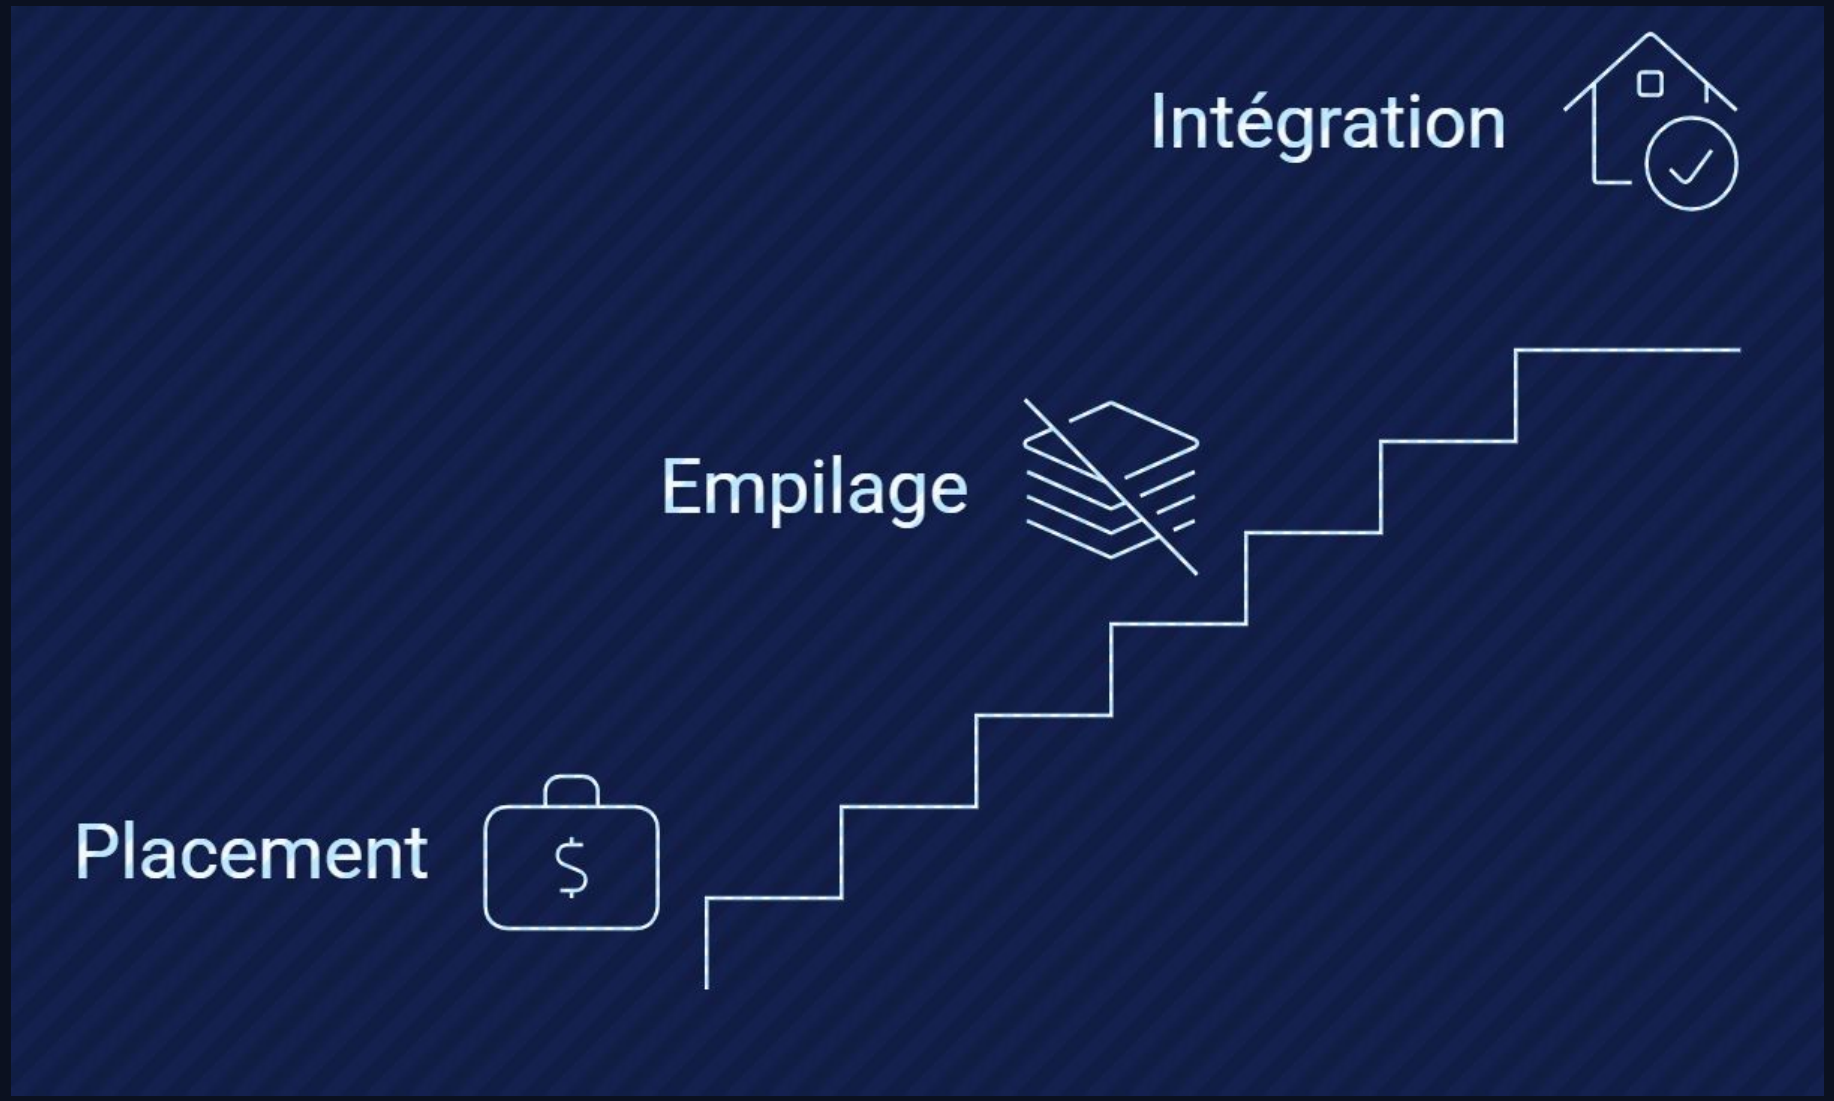
PROJET CONNECT AI — YNOV M1 IA DATA

DÉTECTION AML PAR GNN

Du CSV au Graphe de Connaissances RDF : Améliorer la détection par la topologie du réseau

Samir
KHALDI

PATTERN : BLANCHIMENT D'ARGENT



L'ANOMALIE STRUCTURELLE

APPROCHE TABULAIRE

Anomalie ponctuelle : une ligne "bizarre" isolée (montant excessif). Détection par Random Forest ou Régression Logistique.

APPROCHE GRAPHE

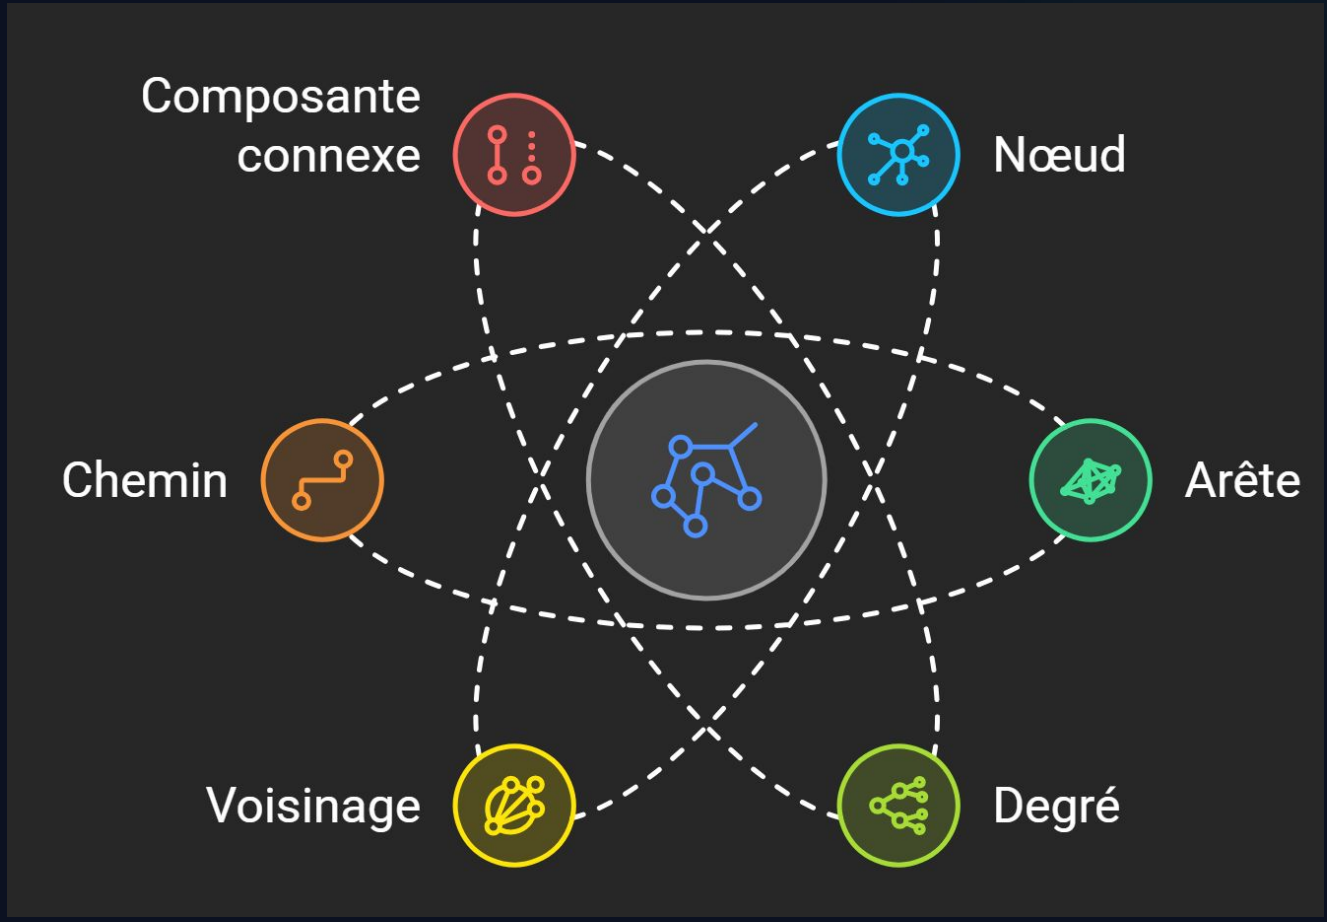
Anomalie structurelle : le crime est dans **l'enchaînement** des flux. Fan-in, relais, cycles. Le GNN "voit" le réseau.

"Dans quelle mesure l'intégration de la topologie via un GNN améliore-t-elle la détection par rapport au supervisé tabulaire ?"

APPROCHE GNN

Qu’est ce qu’un Graph ?

Qu’est ce qu’un Graph Neural Network ?



LE JEU DE DONNÉES IBM AML

31,3 M

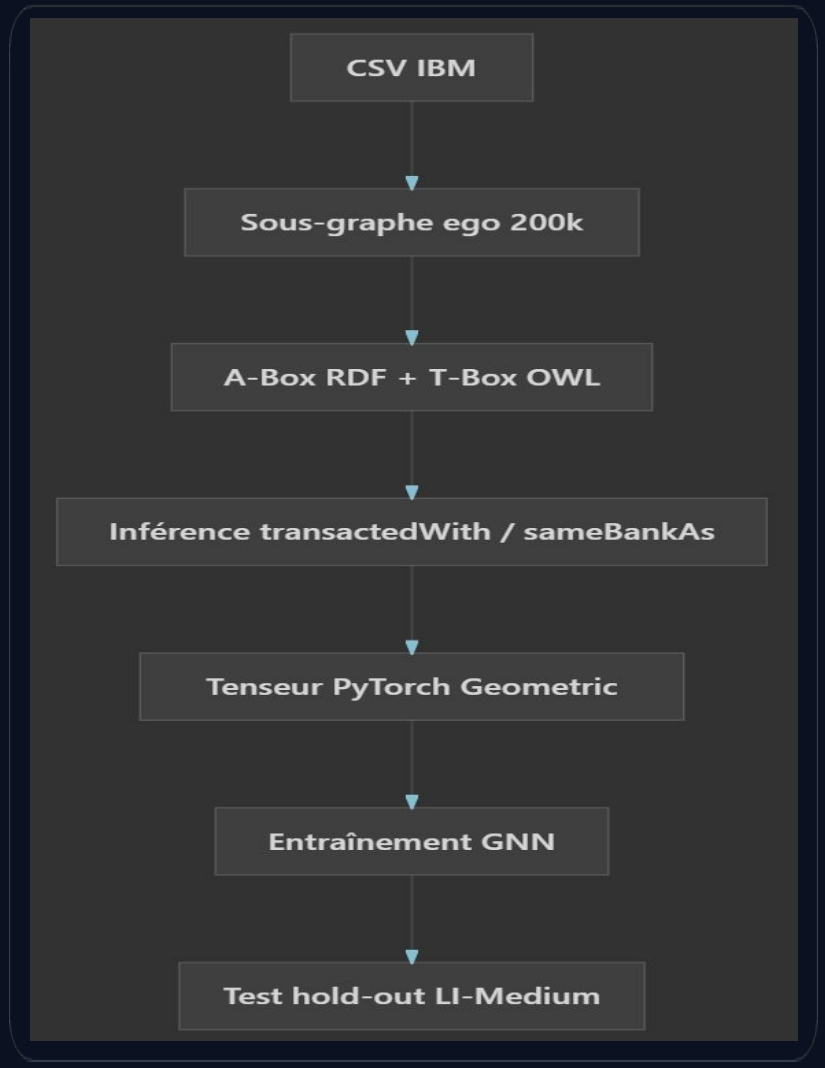
Transactions (LI-Medium)

0,05%

Ratio de Fraude (Réaliste)

- **LI-Small :** ~6,9 M transactions pour l'entraînement.
- **LI-Medium :** Test final hold-out (données jamais vues).
- **Cibles :** Classification binaire.
- **Défis :** Déséquilibre de classe massif.

PIPELINE GLOBAL : DU CSV AU TEST HOLD-OUT



ÉCHANTILLONNAGE "EGO" (200K TX)

Optimisation pour conserver 100% du signal de fraude tout en gérant le volume brut.

Métrique	LI-Small (Train)	LI-Medium (Hold-out)
Transactions (Avant Plafond)	2,45 M	12,1 M
Transactions (Après Ego)	**200 000**	**200 000**
Fraudes Identifiées	3 565 (1,78%)	16 041 (8,02%)
Degré Moyen	3,30	1,85 (Graphe fragmenté)

LE GRAPHE DE CONNAISSANCES RDF/OWL

T-BOX (AML.TTL)

Définition sémantique des classes (Comptes, Banques) et propriétés métier.

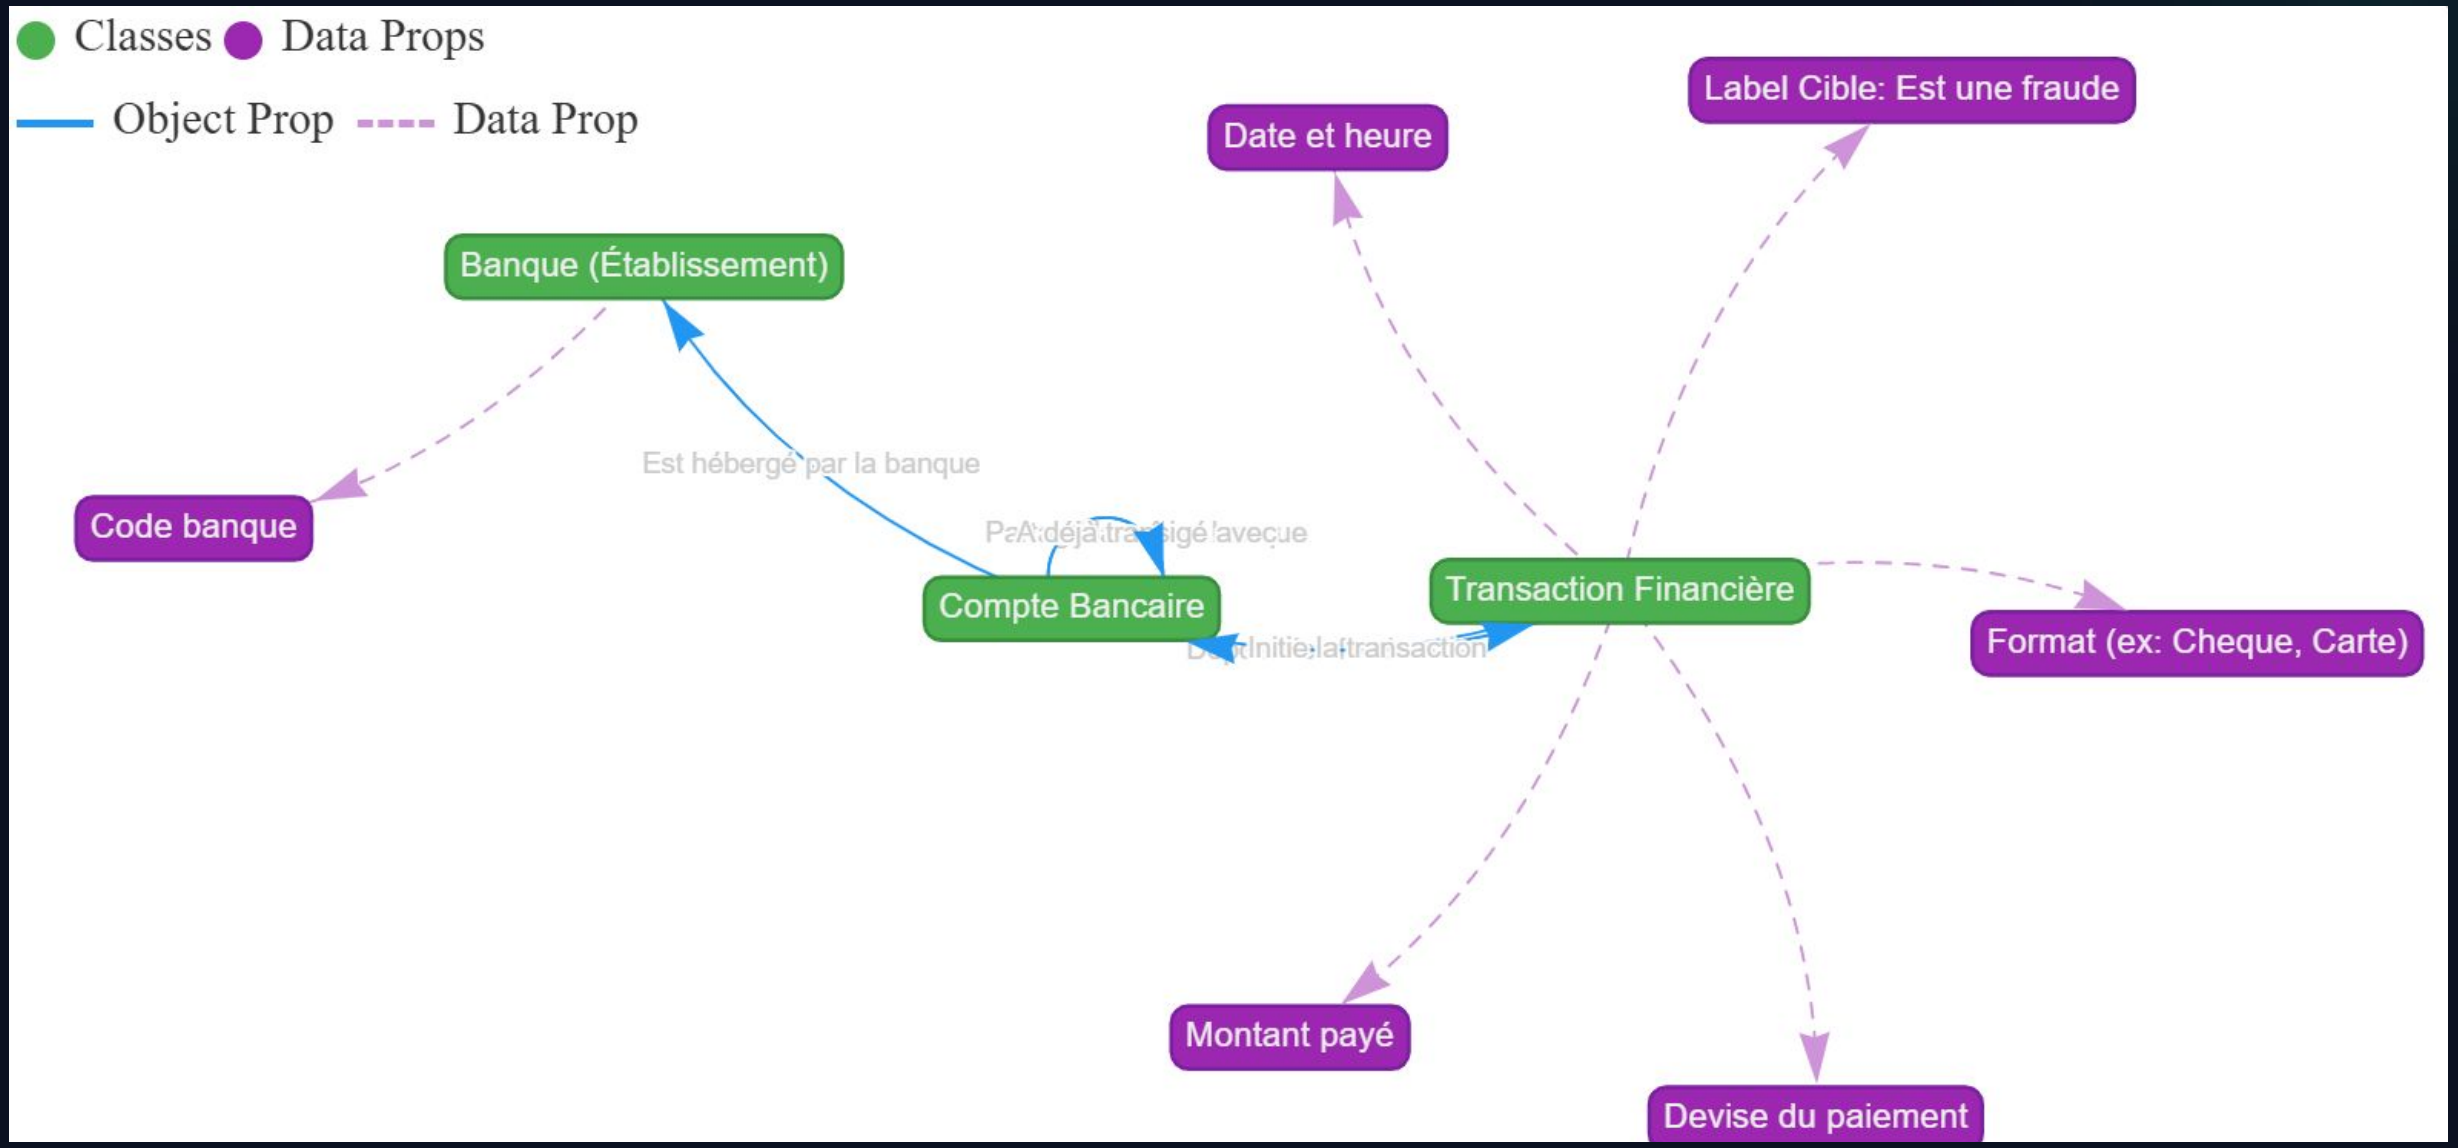
A-BOX (INSTANCES)

Triple S-P-O : (Compte_A) → sends_via → (Transaction_1) → deposits_to → (Compte_B).

INFÉRENCE

Création automatique de liens (sameBankAs) avant l'injection dans le modèle IA.

STRUCTURE DE LA T-BOX



INFÉRENCE : PRÉ-TRAITEMENT INTELLIGENT

transactedWith
Deux comptes ont déjà transigé ensemble directement ou indirectement.

sameBankAs
Appartenance à la même banque avec flux historique.

+225k

Triplets enrichis créés

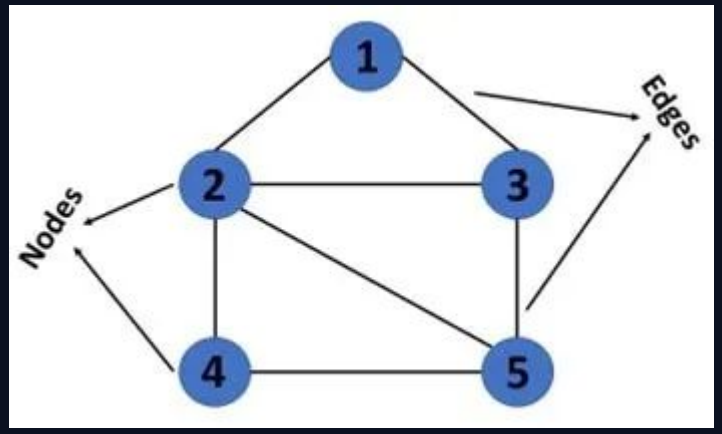
Le GNN reçoit un graphe déjà structuré par le métier au lieu de redécouvrir l'évidence.

HETEROGNN VS GNN HOMOGÈNE

NUANCE MÉTIER

Contrairement au GNN homogène (GraphSAGE/GAT) où tous les liens sont "pareils", notre **HeteroConv** traite chaque type de relation (hosted_by, transacted_with) avec une équation différente.

Le modèle comprend non seulement que A est lié à B, mais **pourquoi** ils le sont.



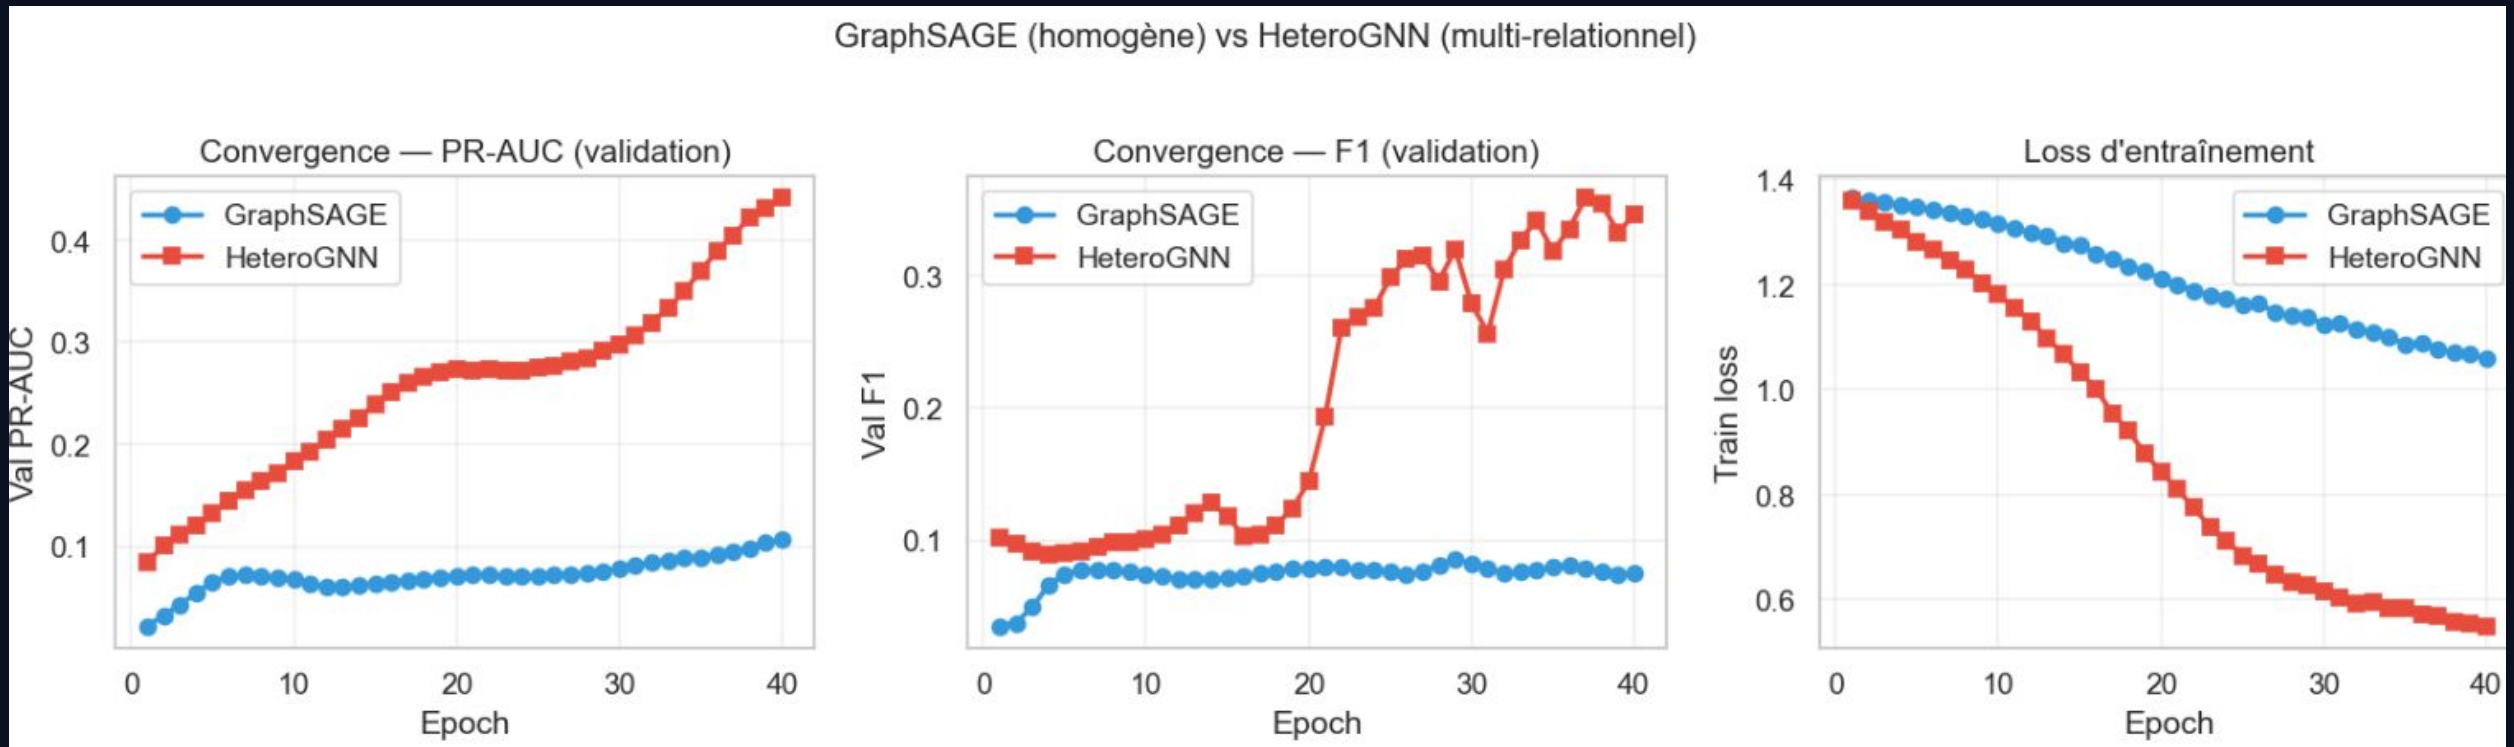
BENCHMARK : MODÈLES TESTÉS

Modèle	Type	Mécanisme Clé
HeteroGNN	Hétérogène (RDF)	Message passing typé par relation (HeteroConv)
GraphSAGE	Homogène	Agrégation simple des voisins (Moyenne)
GAT	Homogène	Mécanisme d'attention sur les voisins

** Loss : BCEWithLogits + pos_weight pour compenser le déséquilibre de classe.*

RÉSULTATS ENTRAÎNEMENT (LI-SMALL)

model	pr_auc	recall	precision	f1
gat	0.046680	0.625468	0.029529	0.056395
hetero	0.429733	0.749064	0.215866	0.335149
sage	0.119386	0.838951	0.038066	0.072828



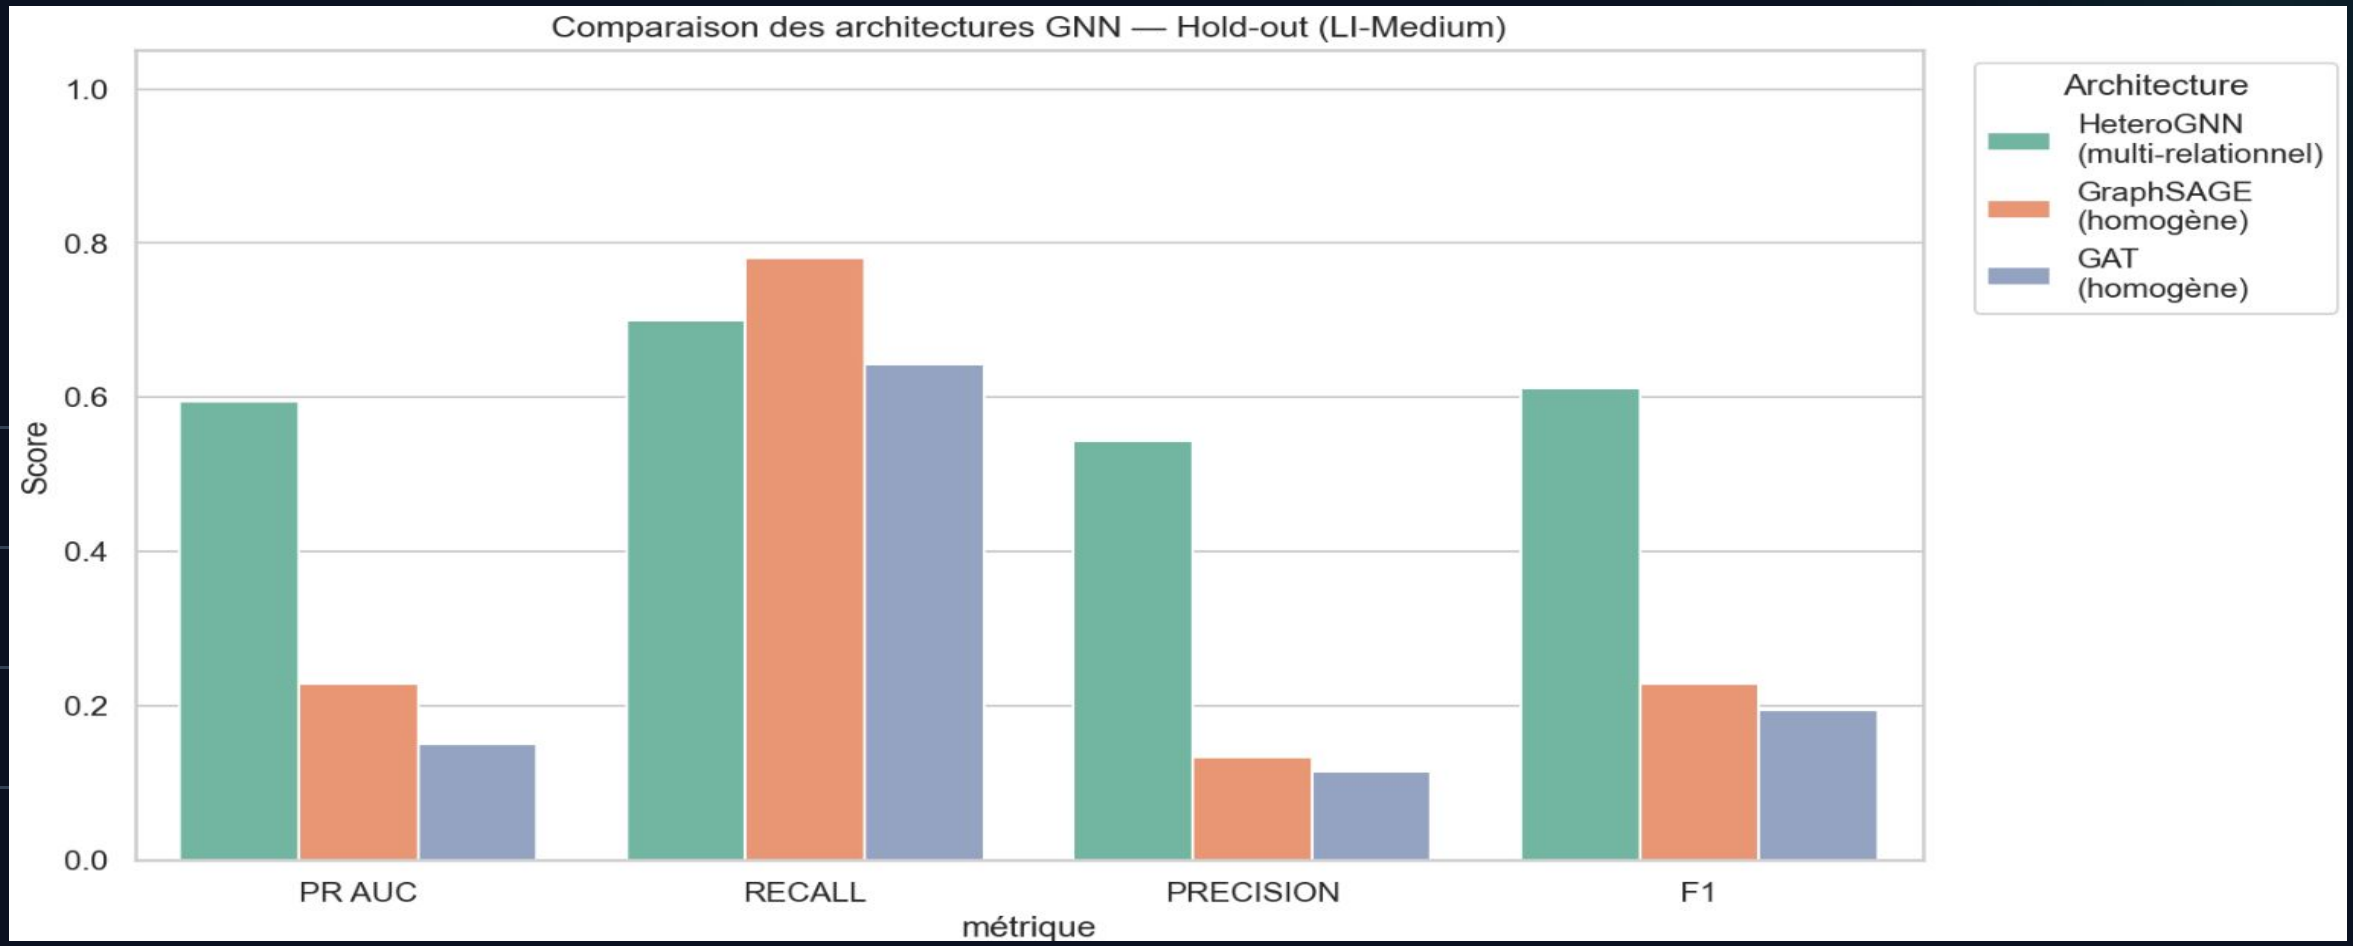
GÉNÉRALISATION : LE TEST HOLD-OUT

Données inconnues (LI-Medium) - Aucun ré-entraînement :

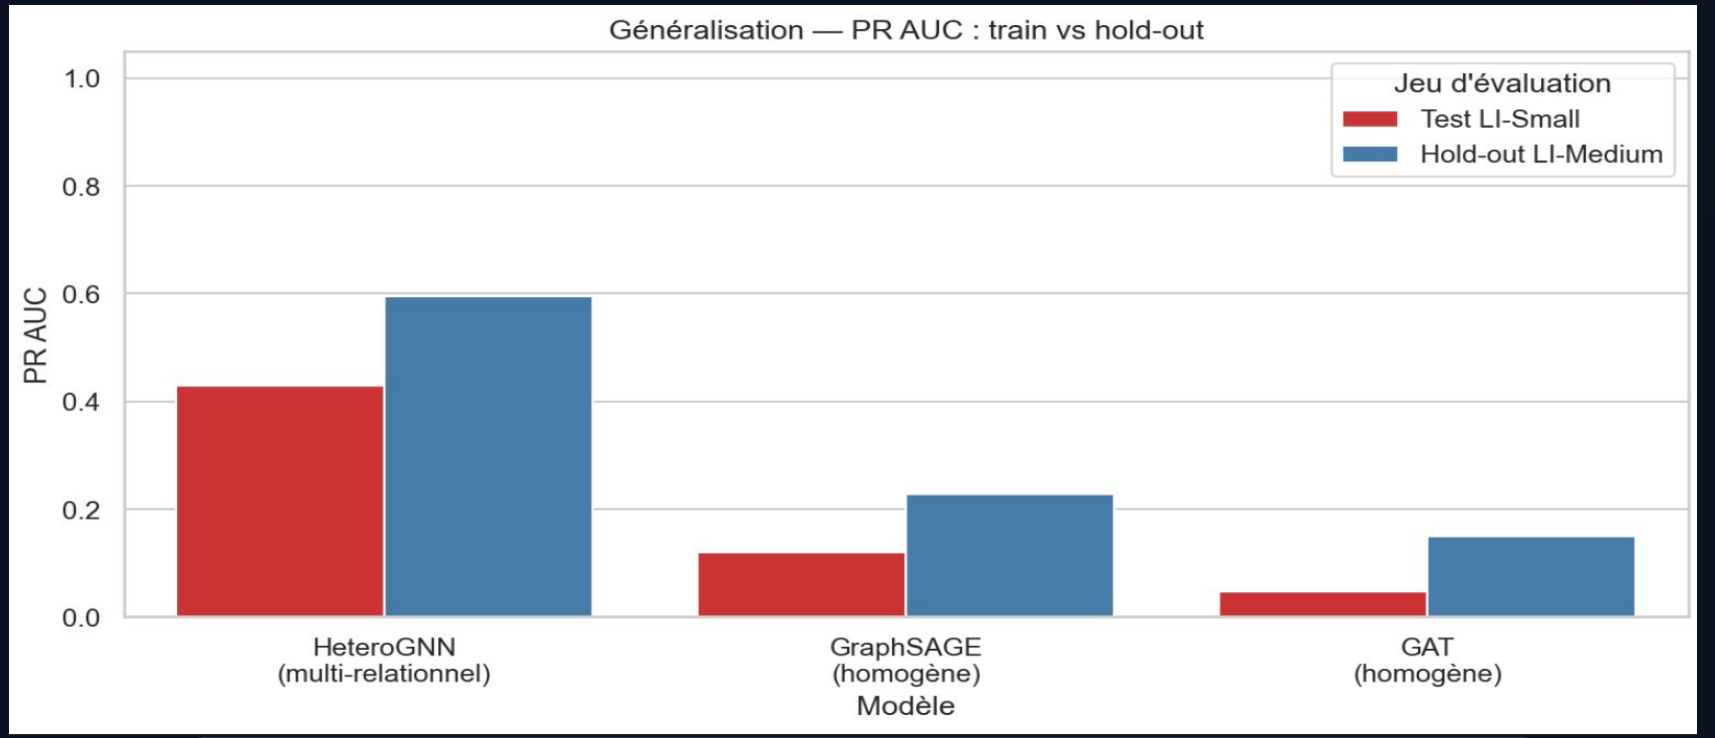
Modèle	PR-AUC	Recall	Precision	F1
HeteroGNN	**0.595**	0.699	**0.544**	**0.612**
GraphSAGE	0.229	0.781	0.133	0.228
GAT	0.150	0.643	0.114	0.194

⚠ Seul le HeteroGNN maintient un équilibre Precision/Recall hors échantillon.

GÉNÉRALISATION : LE TEST HOLD-OUT



CONCLUSION



· Le multi-relationnel surpasse les approches homogènes.

· L'inférence RDF pré-structure efficacement l'apprentissage.

· Le GNN est un complément indispensable au tabulaire pour la détection "layering".

Merci de votre attention.